

Анализ данных на Python

Шкалы данных

Преподаватели: Тамбовцева А.А., Зайцева К.Д.

Шкалы данных

Шкалы данных

Определяют, какие операции можно выполнять с данными

Одно из распространенных делений данных по типам – деление на **количественные** и **качественные** данные.

количественные	дискретные	**количественные дискретные**
	непрерывные	**количественные непрерывные**
качественные (категориальные)	порядковые	**категориальные порядковые**
	номинальные	**категориальные номинальные**
		категориальные бинарные

Шкалы данных

Количественные: дискретные и непрерывные

количественные дискретные

счётное (ограниченное) число возможных значений признака

- число заключённых договоров
- количество участников эксперимента
- число посетителей сайта в некоторый промежуток времени

количественные непрерывные

бесконечное (неограниченное) число возможных значений

- рост и вес
- ВВП на душу населения
- явка в процентах
- температура воздуха

Шкалы данных

Категориальные: порядковые и номинальные

категориальные порядковые

значения признака можно упорядочить

- оценка в 5-балльной шкале
- уровень дохода (высокий / средний / низкий)
- степень согласия с утверждением

категориальные номинальные

значения нельзя упорядочить, сколько угодно значений

- любимый вид кофе
- название региона
- тип политического режима
- участие в выборах (1 – да, 0 – нет)

категориальные бинарные

значения нельзя упорядочить, только два значения

Шкалы данных

Определяют, какие операции можно выполнять с данными

Есть еще более детальное деление на шкалы, где количественную шкалу делят на два подвида: **абсолютная** (шкала отношений) и **интервальная** (шкала разностей).

абсолютная шкала

- с данными в этой шкале можно выполнять те же операции, что и с числами, и это будет осмысленно;
- есть абсолютный ноль, который означает отсутствие признака;
- есть возможность определить, *во сколько раз* одно значение больше другого.

стоимость товара; численность населения страны; число лайков у поста; объём экспорта

интервальная шкала

- установлена точка отсчёта, с которой удобно сравнивать остальные значения;
- значение «ноль» необязательно означает отсутствие признака;
- нет возможности определить, во сколько раз одно значение больше другого, но всегда можно определить *на сколько*.

температура воздуха по Цельсию; год; индекс экологической эффективности; индекс качества городской среды

Перекодирование данных

One-hot encoding

Перевод категориального признака в набор бинарных признаков

Для каждого значения создаем бинарную переменную, где 1 ставится в случае, если признак равен этому значению, 0 – иначе.

	жанр
1	комедия
2	драма
3	ужасы
4	фэнтези
5	драма



	жанр	драма	комедия	ужасы	фэнтези
1	комедия	0	1	0	0
2	драма	1	0	0	0
3	ужасы	0	0	1	0
4	фэнтези	0	0	0	1
5	драма	1	0	0	0

В pandas есть специальная функция get_dummies().

Label encoding

Перекодирование категориального признака в числовые метки

Для каждого значения определяем числовую метку, по умолчанию – просто порядковый номер после упорядочения по алфавиту.

	жанр
1	комедия
2	драма
3	ужасы
4	фэнтези
5	драма

→

	жанр	жанр_код
1	комедия	1
2	драма	0
3	ужасы	2
4	фэнтези	3
5	драма	0

Готовые функции в Python (LabelEncoder в sklearn, например) будут начинать нумерацию с 0.

English, please

Basic terms

quantitative/qualitative data	количественные / качественные данные
continuous/discrete variables	непрерывные / дискретные переменные
nominal/categorical scale	номинальная / категориальная шкала
ordinal scale	порядковая шкала
binary/dichotomous scale	бинарная / дихотомическая шкала
ratio scale/interval scale	шкала отношений / интервальная шкала
scale of measurement	шкала измерения
units of measurement	единицы измерения
data recoding	перекодирование данных
dummy variables	фиктивные переменные
value vs label	значение vs метка (например, значение *male*, метка 1)

Спасибо за внимание!

