

Анализ данных в Python

Описательные статистики

Преподаватели: Тамбовцева А.А., Зайцева К.Д.

Описание количественных данных

Кратко

Меры центральной тенденции для данных в количественной шкале

Нет нетипичных значений

- Среднее
- Медиана

Есть нетипичные значения

- Медиана

Меры изменчивости для данных в количественной шкале

Нет нетипичных значений

- Размах
- Межквартильный размах
- Дисперсия и стандартное отклонение

Есть нетипичные значения

- Межквартильный размах

Раз среднее чувствительно к нетипичных значений, использовать статистики, основанные на среднем, если в данных есть такие значения, нелогично. Но их можно удалить и использовать любые принятые статистики.

Размах на среднем не основан, но его смысл в случае наличия нетипично больших или нетипично маленьких значений теряется. Пример: при выгрузке данных по застройке домов два года склеились, максимальный год постройки дома получился 19791982. Представьте, какой размах мы получим, вычитая из такого максимума минимум.

Описание категориальных данных

Кратко

Данные в порядковой шкале

Мера центральной тенденции

- Медиана

Меры изменчивости

- Размах
- Межквартильный размах

Данные в качественной шкале

Мера центральной тенденции

- Мода – самое частое значение

+ таблицы частот

Так как данные в качественной шкале нельзя упорядочить, определить для них минимум, максимум, среднее и прочие характеристики нельзя. Можно только вычислить частоты – посчитать, сколько раз каждое значение встречается в данных (абсолютные частоты) или выразить то же самое в долях или процентах (относительные частоты).

Описание данных в количественной шкале

Описание выборок

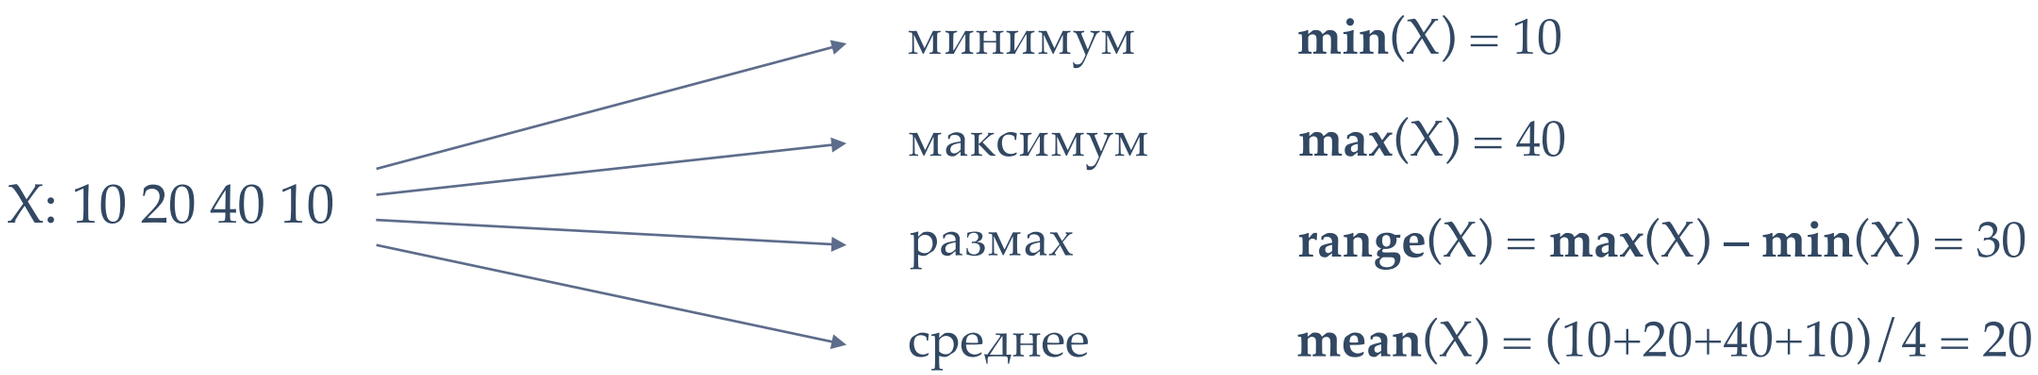
Работа с выборками из данных в количественной шкале

На данном этапе на **выборку** можно смотреть как на набор значений интересующего количественного показателя, который надо как-то охарактеризовать. Позже мы вспомним более формальное определение выборки.

Описательные статистики

- числовые характеристики выборки;
- функции от выборки, которые используются для её описания.

Примеры описательных статистик



Описание выборок

Выборочная медиана

Медиана выборки

- значение, которое 50% наблюдений выборки не превышают

Нахождение медианы

Нечётное число наблюдений

88 74 70 78 57

57 70 **74** 78 88

медиана 74

упорядочить по возрастанию, выбрать значение посередине

Чётное число наблюдений

88 74 70 78 57 57

57 57 **70 74** 78 88

медиана 72

упорядочить по возрастанию, выбрать два значения посередине, посчитать их среднее

Описание выборок

Выборочная медиана

Чем хороша медиана?

- более устойчива к наличию нетипичных – слишком больших или маленьких – значений, чем обычное среднее арифметическое

Пример: иллюстрация устойчивости

Заработная плата в тысячах рублей: 20, 30, 40, 40, 50, 55, 250



медиана: 40
среднее: 69.3

медиана более адекватно отражает ситуацию, а среднее получилось «завышенным» из-за наличия одного человека с очень высокой заработной платой

Описание выборок

Выборочные процентили и квантили

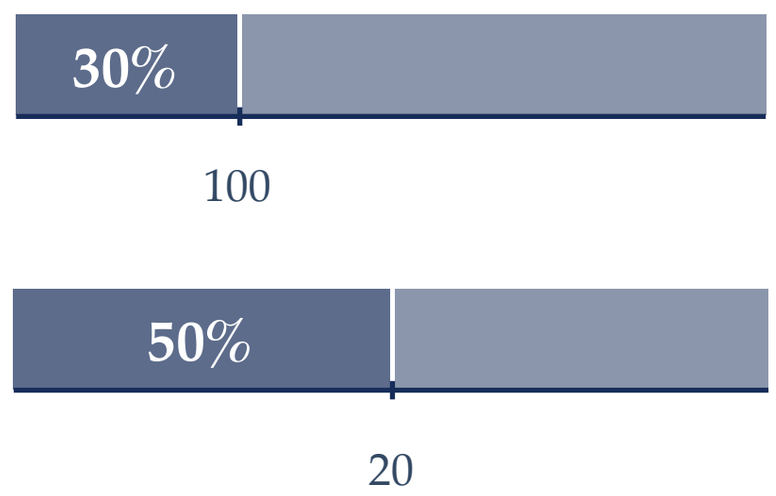
k-тый процентиль = квантиль уровня *k/100*

- значение, которое k% наблюдений выборки не превышают

Примеры

- 30-тый процентиль равен 100 ↔
  квантиль уровня 0.3 равен 100 ↔
  в выборке 30% значений не более 100

- 50-тый процентиль равен 20 ↔
  квантиль уровня 0.5 равен 20 ↔
  медиана выборки равна 20 ↔
  половина значений выборки не более 20



Описание выборок

Частные случаи выборочных квантилей

Выборочные квартили

- значения, которые делят упорядоченную выборку на четыре равные части



Описание выборок

Частные случаи выборочных квантилей

Выборочные децили

- значения, которые делят упорядоченную выборку на десять равных частей



Выборочная дисперсия

Мера изменчивости показателя

Формула

$$s^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n - 1}$$

x_i *i-наблюдение*

$\bar{x}$ *среднее арифметическое*

n *число наблюдений*

Вычитаем из каждого значения выборки среднее арифметическое, разности возводим в квадрат. Разности суммируем. Полученную сумму делим на n–1, где n – число наблюдений в выборке.

Пример вычисления

Выборка значений заработной платы в тысячах рублях

10	25	15	20	30	
x_1	x_2	x_3	x_4	x_5	$\bar{x} = 20$

$$(10 - 20)^2 +$$
$$(25 - 20)^2 +$$
$$(15 - 20)^2 +$$
$$(20 - 20)^2 +$$
$$(30 - 20)^2 =$$
$$\sum = 250$$

$$s^2 = \frac{250}{5 - 1} = \frac{250}{4} = 62.5 \text{ тыс.руб.}^2$$

Выборочное стандартное отклонение

Мера изменчивости показателя

Недостаток дисперсии: дисперсия показателя измерена не в единицах измерения этого показателя, а в квадратах единиц измерения, что снижает интерпретируемость.

Решение простое – извлечь квадратный корень из выборочной дисперсии и вычислить стандартное отклонение выборки.

$$s = \sqrt{s^2}$$

Стандартное отклонение показателя измерено в тех же единицах измерения, что и сам показатель.

Описательные статистики: зачем?

Представляют сводные характеристики данных

Характеризуют распределение данных

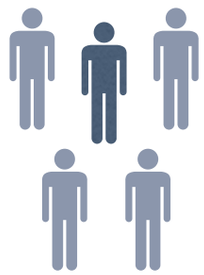
Можем описать данные так:

Возраст	Доля (в %)
10-20	10 %
21-30	40 %
31-40	20 %
41-50	30 %

А можем так:

Медиана	30
Нижний квартиль	23
Верхний квартиль	42

Позволяют описать типичного представителя группы



- Портрет среднестатистического жителя города
- Портрет пользователя электронного сервиса

Обычно под «среднестатистическим» жителем подразумевают некоторый «образ» человека, у которого значения всех показателей равны среднему. Но, как мы знаем, иногда полезно посмотреть на медианные.

Описательные статистики: зачем?

Используются для вычисления сводных количественных показателей

- Соотношение 20/20

  мера имущественного неравенства (доклады ООН), отношение среднего дохода верхних 20% населения к среднему доходу нижних 20% населения

- Децильный коэффициент (коэффициент дифференциации доходов)

  мера имущественного неравенства, отношение среднего дохода верхних 10% населения к среднему доходу нижних 10% населения.

Описательные статистики: зачем?

Позволяют выявить нетипичные значения

Визуальный способ (менее точный)

Сигнал: большая разница между средним арифметическим и медианой

- Среднее >> медиана: в данных есть нетипично большие значения
- Среднее << медиана: в данных есть нетипично маленькие значения



Символы >> и << означают «сильно больше» и «сильно меньше» соответственно.

Формальный способ (более точный)

Вычисление границ характерных значений, используя разные подходы

- Подход 1: основан на межквартильном размахе
- Подход 2: основан на стандартном отклонении

Формальные способы обсудим позже.

Поиск нетипичных значений – выбросов

Поиск выбросов

Критерий 1.5 × IQR для поиска нехарактерных (аномальных) значений

1. Вычисляем нижний квартиль Q1 и верхний квартиль Q3.

2. Вычисляем межквартильный размах IQR:

$$IQR = Q3 - Q1$$

3. Вычисляем границы нетипичных значений:

$$[Q1 - 1.5 \times IQR;\ Q3 + 1.5 \times IQR]$$

4. Все значения, которые лежат внутри полученного отрезка, являются типичными, которые лежат за пределами этого отрезка – нетипичными (нехарактерными) значениями или выбросами.

Источники выбросов: наличие действительно «нестандартных» объектов; ошибки при вводе данных.

Поиск выбросов

Критерий 1.5 × IQR для поиска нехарактерных (аномальных) значений

Пример

Заработная плата в тысячах рублей: 12, 20, 30, 40, 50, 50, 55, 60, 120, 250

Нижний квартиль	Q1 = 30
Верхний квартиль	Q3 = 60
Межквартильный размах	IQR = 60 – 30 = 30
	[Q1 – 1.5 × IQR; Q3 + 1.5 × IQR]
	[30 – 1.5 × 30; 60 + 1.5 × 30]
Границы характерных значений	[–15; 105]

от –15 до 105 – типичные значения
меньше –15 – нехарактерно маленькие значения
больше 105 – нехарактерно большие значения

итого – выбросы 120 и 250

Поиск выбросов

Критерий 2 × STD для поиска нехарактерных (аномальных) значений

1. Вычисляем среднее MEAN и стандартное отклонение STD.

2. Вычисляем границы нетипичных значений:

$$[MEAN - 2 \times STD; MEAN + 2 \times STD]$$

3. Все значения, которые лежат внутри полученного отрезка, являются типичными, которые лежат за пределами этого отрезка – нетипичными (нехарактерными) значениями или выбросами.

Поскольку множитель 2 перед стандартным отклонением можно уточнить (до 1.96, например, если вспомним особенности нормального распределения) или увеличить (до 3, если нас интересуют не просто любые выбросы, а сильно отклоняющиеся значения), часто этот критерий формулируют в более общем виде N × STD, где N – некоторое число, которое зависит от постановки задачи.

Поиск выбросов

Критерий 2 × STD для поиска нехарактерных (аномальных) значений

Пример

Заработная плата в тысячах рублей: 12, 20, 30, 40, 50, 50, 55, 60, 120, 250

Среднее	MEAN = 68.7
Стандартное отклонение	STD = 70.22
Границы характерных значений	[MEAN – 2 × STD; MEAN + 2 × STD] [68.7 – 2 × 70.22; 68.7 + 2 × 70.22] [–71.74; 209.14]

от –71.74 до 209.14 – типичные значения
меньше –71.74 – нехарактерно маленькие значения
больше 209.14 – нехарактерно большие значения

итого – по этому критерию выбросов нет

(однако здесь он ненадёжен – за счёт нехарактерно большого значения 250 среднее завышено + разброс значений велик, стандартное отклонение огромное, выше среднего)

Спасибо за внимание!

